

ANALISIS

1. Modifikasi Arsitektur MLP untuk Mengatasi Underfitting

Underfitting terjadi ketika model terlalu sederhana sehingga tidak dapat menangkap pola dalam data. Jika menggunakan model MLP dengan 3 hidden layer (256-128-64) dan menghasilkan underfitting, kita bisa melakukan beberapa perubahan berikut untuk meningkatkan kinerja model.

Modifikasi yang Bisa Dilakukan:

- Menambah jumlah neuron di hidden layers:
 - Mengapa: Menambah jumlah neuron akan meningkatkan kapasitas model untuk menangkap hubungan yang lebih kompleks antara fitur dan target, sehingga dapat mengurangi underfitting.
 - Contoh: Cobalah meningkatkan jumlah neuron di setiap hidden layer, seperti (512-256-128) atau (512-512-256).
- Menambah jumlah hidden layers:
 - Mengapa: Dengan menambah lebih banyak hidden layers, model dapat menangkap hubungan yang lebih rumit dalam data. Lebih banyak layer akan memungkinkan model untuk mempelajari lebih banyak non-linearitas.
 - Contoh: Cobalah arsitektur dengan lebih banyak layer, seperti (256-128-64-32).
- Mengurangi regularisasi:
 - Mengapa: Jika Anda menggunakan teknik seperti dropout atau L2 regularization untuk menghindari overfitting, mungkin perlu mengurangi kekuatan regularisasi untuk memberi model lebih banyak ruang untuk belajar.

Bias-Variance Tradeoff:

- Bias: Arsitektur yang ada kemungkinan memiliki bias yang tinggi (underfitting). Hal ini disebabkan oleh model yang terlalu sederhana sehingga tidak bisa menangkap pola yang kompleks.
- Variance: Menambah jumlah layer atau neuron akan meningkatkan kompleksitas model, yang bisa meningkatkan variance. Namun, jika model Anda underfitting, maka perubahan ini adalah trade-off yang baik untuk mengurangi bias.

2. Alternatif Fungsi Loss Selain MSE

Walaupun MSE (Mean Squared Error) sering digunakan untuk tugas regresi, ada beberapa fungsi loss lain yang mungkin lebih sesuai dengan dataset tertentu.

Alternatif Fungsi Loss:

- MAE (Mean Absolute Error):
 - Keunggulan: MAE lebih tahan terhadap outliers dibandingkan MSE karena tidak membesar-besarkan kesalahan yang lebih besar.
 - Kelemahan: MAE tidak membedakan besar kesalahan dengan sekuat MSE, yang bisa mengurangi ketepatan jika kesalahan besar sangat penting.

- Penggunaan: MAE lebih baik digunakan pada dataset yang mengandung banyak outliers, di mana kita tidak ingin kesalahan besar terlalu mempengaruhi model.
- Huber Loss:
 - Keunggulan: Menggabungkan MSE dan MAE, dengan memberikan hukuman kuadratik untuk kesalahan kecil dan hukuman linear untuk kesalahan besar.
 - Kelemahan: Memerlukan pengaturan parameter untuk memilih batas antara MSE dan MAE.
 - Penggunaan: Cocok digunakan pada dataset yang mengandung outliers moderat karena mengurangi dampak outliers tanpa mengorbankan informasi dari kesalahan kecil.
- Quantile Loss:
 - Keunggulan: Berguna untuk quantile regression, di mana Anda ingin memprediksi nilai pada persentil tertentu (misalnya median atau 90th percentile), bukan hanya rata-rata.
 - Kelemahan: Memerlukan pemilihan quantile yang tepat.
 - Penggunaan: Cocok ketika kita ingin memprediksi persentil tertentu dari distribusi data, bukan hanya nilai rata-rata.

3. Pengaruh Skala Fitur terhadap Pelatihan MLP

Jika satu fitur memiliki rentang nilai 0-1 dan fitur lainnya 100-1000, ini bisa memengaruhi proses pelatihan MLP secara negatif.

Dampak Matematis:

- Gradient Descent: Selama pelatihan menggunakan gradient descent, pembaruan bobot dilakukan berdasarkan gradien yang dihitung untuk masing-masing fitur. Fitur dengan rentang lebih besar (100-1000) akan memiliki gradien lebih besar dan mendominasi pembaruan bobot. Fitur dengan rentang kecil (0-1) akan memiliki gradien yang lebih kecil, sehingga tidak berkontribusi seimbang.
- Pembaharuan Bobot: Fitur dengan rentang lebih besar akan menyebabkan pembaruan bobot yang lebih besar, sedangkan fitur dengan rentang kecil dapat memperlambat pembelajaran dan menyebabkan model kesulitan dalam belajar.

Solusi:

- Standardisasi (Z-Score Normalization): Semua fitur perlu diskalakan ke rentang yang serupa, misalnya dengan standardisasi (mean = 0, standar deviasi = 1) untuk memastikan kontribusi setiap fitur terhadap pembaruan bobot sama.
- `scaler = StandardScaler()`
- `X_train_scaled = scaler.fit_transform(X_train)`
- `X_test_scaled = scaler.transform(X_test)`

4. Mengukur Kontribusi Fitur Tanpa Nama Fitur

Jika tidak tahu nama fitur, masih bisa diukur dengan kontribusi relatif setiap fitur terhadap prediksi model menggunakan beberapa metode.

Metode:

a) Permutation Importance:

- Deskripsi: Fitur yang diacak (shuffling) satu per satu, dan melihat seberapa banyak penurunan kinerja model terjadi. Fitur yang menyebabkan penurunan terbesar dianggap paling penting.
- Keunggulan: Mudah diterapkan, tidak bergantung pada model.
- Kelemahan: Memerlukan waktu komputasi yang besar jika dataset besar.

b) Analisis Bobot (untuk model linear atau MLP):

- Deskripsi: Dalam model linear atau MLP, Anda dapat melihat bobot yang dipelajari oleh model untuk setiap fitur pada layer pertama atau layer output. Bobot dengan nilai absolut lebih besar menandakan bahwa fitur tersebut lebih penting.
- Keunggulan: Langsung dapat dilihat pada model linear.
- Kelemahan: Sulit untuk diinterpretasikan pada model non-linear seperti MLP atau CNN.

c) SHAP (SHapley Additive exPlanations):

- Deskripsi: Menghitung kontribusi masing-masing fitur terhadap prediksi model menggunakan teori nilai Shapley dari teori permainan.
- Keunggulan: Memberikan penjelasan yang lebih mendalam untuk setiap prediksi dan bisa digunakan pada model apapun.
- Kelemahan: Sangat memerlukan waktu komputasi yang besar.

Keterbatasan:

- Permutation Importance membutuhkan pengulangan eksperimen dan bisa lambat jika dataset besar.
- SHAP mahal secara komputasi, terutama untuk model kompleks dan dataset besar.

5. Desain Eksperimen untuk Memilih Learning Rate dan Batch Size

Pemilihan learning rate dan batch size yang optimal sangat penting untuk kestabilan dan efisiensi pelatihan.

Desain Eksperimen:

a) Learning Rate:

- Eksperimen: Mulai dengan rentang learning rate (misalnya 0.001, 0.01, 0.1), dan lakukan grid search atau random search untuk menemukan learning rate yang memberikan performa terbaik pada data validasi.
- Scheduler: Gunakan learning rate scheduler untuk menurunkan learning rate seiring berjalannya waktu, misalnya dengan exponential decay atau step decay.

b) Batch Size:

- Coba berbagai batch size (misalnya 32, 64, 128), karena batch kecil memberikan estimasi gradien yang lebih bervariasi (bisa menjadi bentuk regularisasi) tetapi mungkin lebih lambat.
- Batch yang lebih besar memberikan estimasi gradien yang lebih stabil tetapi bisa membutuhkan lebih banyak memori.

Tradeoff:

- Learning Rate:

- Terlalu tinggi: Bisa menyebabkan model instabil atau overshoot.
- Terlalu rendah: Akan memperlambat konvergensi.
- Learning rate decay: Mengurangi learning rate selama pelatihan untuk mendapatkan hasil lebih stabil.

- Batch Size:

- Batch kecil memberikan lebih banyak noise pada gradien yang bisa membantu regularisasi tetapi membutuhkan lebih banyak iterasi.
- Batch besar lebih stabil dalam estimasi gradien, tapi membutuhkan memori lebih besar dan bisa lebih lambat dalam training.

Kesimpulan:

1. MLP Modifikasi untuk Underfitting: Tambah layer/neurons, atau kurangi regularisasi.
2. Alternatif Loss Function: Gunakan MAE, Huber, atau Quantile Loss sesuai dengan dataset.
3. Skala Fitur: Pastikan fitur distandarisasi agar gradien tidak terdistorsi.
4. Kontribusi Fitur: Gunakan permutation importance, SHAP, atau analisis bobot.
5. Optimalisasi Learning Rate & Batch Size: Gunakan eksperimen grid search dan pertimbangkan trade-off antara komputasi dan stabilitas pelatihan.